

Proyecto I: Reconocimiento de comandos de voz y despliegue móvil con ONNX Runtime Mobile

Fabrizio Mena Mejía

Instituto Tecnológico de Costa Rica

Email: fabriciomena11@estudiantec.cr

Anthony Fuentes Calvo

Instituto Tecnológico de Costa Rica

Email: anthonyfuentescalvo@estudiantec.cr

Fernando Sánchez Hidalgo

Instituto Tecnológico de Costa Rica

Email: Fer.sanchez@estudiantec.cr

Abstract—Este trabajo aborda la clasificación de comandos de voz en el subconjunto de diez etiquetas del conjunto *Speech Commands v0.02*, representando cada utterance como un mel-espectrograma tratado como imagen en escala de grises de 128×128 píxeles. Se comparan dos arquitecturas convolucionales: un LeNet-5 adaptado con activaciones Tanh y un MobileNetV2 adaptado a un canal, entrenadas con PyTorch bajo seis escenarios distintos (datos crudos versus aumentados con desplazamiento temporal, ruido blanco y SpecAugment) y tres configuraciones de hiperparámetros por escenario, totalizando doce entrenamientos. Las métricas en el conjunto de prueba oficial muestran que MobileNetV2 supera claramente a LeNet-5 en exactitud y F1 macro, alcanzando hasta 0.9633 de *accuracy* en la mejor configuración con datos crudos. El monitoreo de curvas y métricas por corrida se registró en *Weights & Biases*. Se describe además el flujo de preprocesamiento reproducible, la política de congelación y exportación a ONNX prevista para inferencia con ONNX Runtime Mobile, la verificación de paridad frente a PyTorch y el enlace entre la salida del clasificador y las acciones de una aplicación Android de hogar inteligente desarrollada con Jetpack Compose.

Index Terms—Comandos de voz, mel-espectrograma, redes neuronales convolucionales, aumentación de datos, *Weights & Biases*, ONNX, ONNX Runtime Mobile.

I. MARCO TEÓRICO

La clasificación de audio corto puede formularse como reconocimiento de patrones en una imagen tiempo-frecuencia: a partir de una forma de onda muestreada se calcula una transformada de Fourier de tiempo corto (STFT) y un banco de filtros mel que aproxima la percepción humana de tono; el logaritmo de la energía mel amortigua la dinámica y facilita el entrenamiento de redes profundas [6]. Las redes neuronales convolucionales (CNN) en dos dimensiones extraen jerarquías locales de texturas y formas en ese mapa, de forma análoga a la visión por computador aplicada a representaciones espectrales.

Para mejorar la generalización bajo ruido y variaciones de canal, es habitual aplicar aumentación en el dominio del tiempo (p.ej. desplazamiento) y en el espectro; SpecAugment enmascara franjas de tiempo y frecuencia en el mel-espectrograma durante el entrenamiento, obligando al modelo a no depender de un único bin o frame [1].

En dispositivos móviles, conviene separar entrenamiento (PyTorch) e inferencia ligera: exportar el grafo a ONNX en modo evaluación, con pesos congelados, y ejecutarlo con ONNX Runtime Mobile reduce dependencias y habilita optimizaciones de tiempo de ejecución [2]. La calidad del despliegue exige que el preprocesamiento en el terminal replique

fielmente el usado al entrenar; la discrepancia se controla con pruebas de paridad logit-a-logit entre PyTorch y el runtime ONNX [2].

II. DATASET Y PREPROCESAMIENTO

A. *Speech Commands v0.02* y subconjunto de diez clases

Se utilizó el conjunto *Speech Commands v0.02* distribuido por TensorFlow Datasets [5], compuesto por grabaciones en formato WAV de un segundo o menos, organizadas en carpetas por etiqueta léxica. Siguiendo el alcance del proyecto, se trabajó con diez comandos: yes, no, up, down, left, right, on, off, stop y go.

B. División entrenamiento, validación y prueba

La partición oficial del corpus se respeta mediante los archivos `validation_list.txt` y `testing_list.txt` incluidos en la raíz del dataset: las rutas listadas en ellos definen los conjuntos de validación y de prueba, respectivamente. El entrenamiento comprende el resto de archivos `.wav` de las diez clases que no aparecen en dichas listas, lo que garantiza que no haya solapamiento de hablantes ni clips entre particiones y que los resultados sean comparables con la literatura.

C. Representación tipo imagen y flujo reproducible

Cada clip se re-muestrea a mono PCM de 16 kHz y se recorta o rellena a una ventana fija de un segundo antes del análisis espectral. En el cuaderno de entrenamiento (`proy1.ipynb`) la STFT utiliza `n_fft=1024`, `hop_length=256` y `n_mels=128`; el mel-espectrograma en escala logarítmica se normaliza por muestra y se re-escala espacialmente a 128×128 , produciendo tensores de forma $(1, 128, 128)$ compatibles con las entradas descritas en las Tablas I y II. Herramientas auxiliares del repositorio documentan además un contrato de preprocesamiento alternativo (p.ej. otros tamaños de FFT) orientado a paridad con tiempo de ejecución ligero; cualquier despliegue debe fijar un único contrato y ceñirse a él de extremo a extremo.

La reproducibilidad se apoya en la semilla global 42 (Sección siguiente), en el uso determinista de las listas oficiales de validación y prueba y en la trazabilidad de hiperparámetros y curvas en *Weights & Biases*.

III. DISEÑO DE ARQUITECTURA DE IA

A. Control de Aleatoriedad y Reproducibilidad

Para garantizar la reproducibilidad de los experimentos, se implementó un estricto control de aleatoriedad. Se definió una semilla global (*seed* = 42) utilizada para inicializar los generadores de números pseudoaleatorios de las librerías *random*, *numpy* y *torch*. Adicionalmente, se configuró el comportamiento determinista de cuDNN desactivando el *benchmark* dinámico donde fuera necesario.

B. Selección de Técnicas de Aumentación de Datos

Para mejorar la capacidad de generalización de los modelos y simular condiciones realistas de entorno (ruido de fondo, variabilidad de hablantes), se aplicaron técnicas de aumento de datos (*data augmentation*) en el preprocesamiento de audio. Las técnicas se inspiraron en métodos avanzados de aumento espectral y en el dominio del tiempo:

- **Time Shift:** Desplazamiento temporal aleatorio para que el sistema aprenda predicciones invariantes al milise-gundo exacto de reproducción, alineándose directamente con aplicaciones reales bajo ruidos dispares.
- **Ruido Blanco (White Noise):** Inyectado progresivamente para simular grabaciones en ambientes no controlados y servir de fuerte regularización matemática de los tensores.
- **SpecAugment [1]:** Enmascaramiento de bloques de frecuencias y tiempo directamente sobre el mel-espectrograma para forzar a la red neuronal a no depender de características auditivas frágiles y lograr márgenes más robustos.

C. Modelo A: LeNet-5 Adaptado

El Modelo A está basado en la arquitectura clásica de LeNet-5, pero fue adaptado específicamente para el procesamiento de mel-espectrogramas.

1) *Justificación de modificaciones:* Se realizaron los siguientes cambios sobre la arquitectura original de LeCun:

- **Tamaño de entrada:** Se modificó para recibir tensores de $1 \times 128 \times 128$ correspondientes a las imágenes generadas del audio, en lugar de los 32×32 originales.
- **Filtros convolucionales:** Se aumentó el número de canales a 32, 64 y 128 en las tres capas convolucionales consecutivas para capturar patrones espectrales más ricos y complejos.
- **Función de Activación:** Se preserva el uso de la función de activación clásica Tanh estipulada en la arquitectura original de LeNet-5. Esto se hace en estricto cumplimiento con los requerimientos del proyecto que limitan el uso de funciones más modernas como ReLU, garantizando así que el modelo mantenga la esencia matemática clásica de la red mientras se adapta al dominio de audio.
- **Padding:** En las capas convolucionales iniciales se utiliza un *padding*=0, consistentemente con la versión clásica de LeNet. Esta elección genera una reducción espacial después de cada convolución antes del AvgPool2d, lo que

simplifica el diseño y mantiene la estructura de extracción de características sin introducir ceros adicionales en los bordes.

- **Clasificador 100% Convolutivo:** Se reemplazó la sección tradicional de capas totalmente conectadas (*Fully Connected*) por una operación de *Global Average Pooling* seguida de convoluciones 1×1 . Esta modificación reduce significativamente el número de parámetros y mitiga el sobreajuste (*overfitting*), preparando el modelo para su futuro despliegue en dispositivos móviles donde los parámetros en capas densas consumen demasiada memoria RAM.

2) *Definición de la Arquitectura:* La arquitectura final se resume en el diagrama presentado en la Tabla I. Consta de tres bloques convolucionales iniciales con *Average Pooling*, seguidos de una capa de *Global Average Pooling* y un bloque clasificador compuesto exclusivamente por convoluciones de 1×1 .

TABLE I
DIAGRAMA DE CAPAS - LeNET-5 ADAPTADO

Capa / Operación	Dimensión de Salida
Input (Mel-Spectrogram)	$(B, 1, 128, 128)$
Conv1 ($32 \times 5 \times 5$) + Tanh + AvgPool(2)	$(B, 32, 62, 62)$
Conv2 ($64 \times 5 \times 5$) + Tanh + AvgPool(2)	$(B, 64, 29, 29)$
Conv3 ($128 \times 5 \times 5$) + Tanh + AvgPool(2)	$(B, 128, 12, 12)$
Global Average Pooling	$(B, 128, 1, 1)$
Conv4 ($128 \rightarrow 512, 1 \times 1$) + Tanh	$(B, 512, 1, 1)$
Conv5 ($512 \rightarrow 128, 1 \times 1$) + Tanh	$(B, 128, 1, 1)$
Conv6 ($128 \rightarrow 10, 1 \times 1$) (Logits)	$(B, 10, 1, 1)$
Flatten Final	$(B, 10)$




Fig. 1. Diagrama visual de la arquitectura del Modelo A.

3) *Función de Pérdida, Optimizador y Entrenamiento:* Se utilizó *Cross-Entropy Loss* como función de pérdida, la cual es ideal para clasificación multiclase. El optimizador seleccionado fue Adam con una tasa de aprendizaje de 1×10^{-3} y *weight decay* de 1×10^{-4} para mitigar el sobreajuste. Además, se empleó un *scheduler* (ReduceLROnPlateau) que reduce la tasa de aprendizaje a la mitad si la precisión de validación no mejora en 3 épocas. Las rutinas de entrenamiento se ejecutaron usando precisión mixta nativa (*torch.amp*).

D. Modelo B: MobileNetV2 Adaptado

El Modelo B está basado en la arquitectura de MobileNetV2, reconocida por su alta eficiencia y bajo consumo de parámetros en dispositivos móviles. Esta red fue programada

de manera estructurada y adaptada específicamente para la clasificación de audio mediante espectrogramas de Mel.

1) *Justificación de modificaciones:* Se instrumentaron los siguientes cambios respecto a la arquitectura estándar de MobileNetV2 para adaptarla plenamente al dominio de audio:

- **Tamaño de entrada y 1 Canal:** La capa convolucional inicial (que utiliza un bloque de *Conv2d* + *BatchNorm* + *ReLU6*) recibe un tensor adaptado a un solo canal, correspondiente a imágenes en escala de grises de mel-espectrogramas ($1 \times 128 \times 128$), en contraste con los comunes $3 \times 224 \times 224$ (RGB) de ImageNet.
- **Uso de Inverted Residuals:** Se conservó la topología matricial de bloques convolucionales de tipo *Inverted Residual* provista por redes convolucionales mutuamente separables (*Depthwise Separable Convolutions*), con el propósito fundamental de reducir a niveles ínfimos el costo de operaciones en hardware móvil.
- **Clasificador Lineal y Reducción de Ruido:** El tensor de la extracción de características finaliza su procesamiento en una capa *Global Average Pooling*. A continuación se aplica una capa reguladora *Dropout* ($p = 0.2$) para estabilizar la varianza, resolviendo hacia una sola capa lineal enfocada a clasificar los comandos correspondientes.

2) *Definición de la Arquitectura:* La secuencia en su estructura se presenta en la Tabla II. Consiste en un bloque inicial expansivo, siete etapas secuenciadas que usan estructuras *Inverted Residual* con distintas profundidades en factor (t, c, n, s) para extracción iterativa y eficiente, así como un último subconjunto con promediado de vectores lineales.

TABLE II
DIAGRAMA DE CAPAS - MOBILENETV2 ADAPTADO

Capa / Operación	Dimensión / Canal
Input (Mel-Spectrogram)	$(B, 1, 128, 128)$
Conv1 ($1 \rightarrow 32, 3 \times 3$) + BN + ReLU6	$(B, 32)$ <i>Stride 2</i>
Inverted Residual 1 ($t = 1, c = 16, n = 1, s = 1$)	$(B, 16)$
Inverted Residual 2 ($t = 6, c = 24, n = 2, s = 2$)	$(B, 24)$
Inverted Residual 3 ($t = 6, c = 32, n = 3, s = 2$)	$(B, 32)$
Inverted Residual 4 ($t = 6, c = 64, n = 4, s = 2$)	$(B, 64)$
Inverted Residual 5 ($t = 6, c = 96, n = 3, s = 1$)	$(B, 96)$
Inverted Residual 6 ($t = 6, c = 160, n = 3, s = 2$)	$(B, 160)$
Inverted Residual 7 ($t = 6, c = 320, n = 1, s = 1$)	$(B, 320)$
Conv Pointwise (1×1) + BN + ReLU6	$(B, 1280)$
Global Average Pooling	$(B, 1280)$
Dropout ($p = 0.2$) + Linear ($1280 \rightarrow 10$)	$(B, 10)$




Fig. 2. Diagrama visual de la arquitectura del Modelo B.

3) *Función de Pérdida, Optimizador y Entrenamiento:* Del mismo modo que en el modelo A, se adoptó como función de pérdida la *Cross-Entropy Loss* al ser la más

robusta para clases multivariadas. Respecto a la optimización, se ajustó al uso del algoritmo Adam, manteniendo ratios controlados bajo reducción (*Weight Decay* y un programa de control *ReduceLROnPlateau*) aprovechando implementaciones de cálculo por precisión geométrica (*torch.amp*) para reducir la memoria total GPU.

IV. ANÁLISIS Y COMPARACIÓN DE RESULTADOS

A. Registro de experimentos con Weights & Biases

Para cumplir con la rúbrica de trazabilidad, cada una de las doce corridas de entrenamiento se instrumentó con Weights & Biases (W&B) [3]: por época se registraron, entre otras, la pérdida de entrenamiento, la exactitud y el F1 macro en validación, y al finalizar el entrenamiento las métricas agregadas en el conjunto de prueba junto con la matriz de confusión como imagen. Los proyectos y tableros permiten comparar curvas entre configuraciones y entre variantes con y sin aumentación.

En este trabajo, el Modelo A (LeNet-5) quedó consolidado en el proyecto público <https://wandb.ai/fabricsmenamejia-tec-costa-rica/speech-commands-model-a>; las corridas del Modelo B pueden agruparse en un proyecto hermano con la misma convención de nombres de métricas para facilitar la revisión docente.



Fig. 3. Vista del proyecto en Weights & Biases: métricas por corrida (captura a incorporar).

La Tabla III consolida en una sola vista los resultados de *test* de los doce entrenamientos (dos arquitecturas $\times$ dos regímenes de datos $\times$ tres configuraciones de hiperparámetros), alineados con las tablas detalladas en las subsecciones posteriores.

TABLE III
MÉTRICAS EN EL CONJUNTO DE PRUEBA: LAS DOCE CORRIDAS EXPERIMENTALES.

Modelo	Datos	Cfg	Accuracy	F1 macro	Loss
A (LeNet-5)	crudos	1	0.6388	0.6344	1.0522
A (LeNet-5)	crudos	2	0.8883	0.8880	0.3475
A (LeNet-5)	crudos	3	0.7074	0.7034	0.8022
A (LeNet-5)	aumentados	1	0.8271	0.8262	0.5050
A (LeNet-5)	aumentados	2	0.8322	0.8316	0.4863
A (LeNet-5)	aumentados	3	0.8016	0.8004	0.5796
B (MobileNetV2)	crudos	1	0.9592	0.9590	0.1826
B (MobileNetV2)	crudos	2	0.9552	0.9551	0.2073
B (MobileNetV2)	crudos	3	0.9633	0.9631	0.1430
B (MobileNetV2)	aumentados	1	0.9497	0.9493	0.2317
B (MobileNetV2)	aumentados	2	0.9435	0.9430	0.2534
B (MobileNetV2)	aumentados	3	0.9507	0.9503	0.1523

B. Modelo A: Datos crudos

Para evaluar rigurosamente la arquitectura LeNet-5 adaptada a mel-espectrogramas con el uso de datos crudos (sin aumento), se diseñaron iteraciones con tres configuraciones de hiperparámetros distintas durante la fase de entrenamiento:

- **Configuración 1:** Tasa de aprendizaje (LR) de 1×10^{-3} , tamaño de lote (BS) de 128, y manejador ReduceLROnPlateau (factor=0.5, patience=3).
- **Configuración 2:** Tasa de aprendizaje de 5×10^{-4} , tamaño de lote de 64, y el programador StepLR (step_size=10, gamma=0.5).
- **Configuración 3:** Tasa de aprendizaje más alta de 2×10^{-3} , tamaño de lote de 256, y ReduceLROnPlateau más agresivo (factor=0.3, patience=5).

Los resultados globales consolidados para cada ensayo sobre el conjunto de prueba (Test) se registran en la Tabla IV.

TABLE IV
RESULTADOS POR CONFIGURACIÓN - MODELO A (DATOS CRUDOS)

Configuración	Accuracy	F1-Score (Macro)	Loss
Configuración 1	0.6388	0.6344	1.0522
Configuración 2	0.8883	0.8880	0.3475
Configuración 3	0.7074	0.7034	0.8022

A partir de las métricas expuestas, es evidente que la **Configuración 2** resulta ser el mejor modelo. Al combinar una tasa de aprendizaje moderada con un menor tamaño de lote (64) y reducciones escalonadas (StepLR), el modelo evitó caer tempranamente en mínimos locales u oscilar sin convergencia, mejorando considerablemente su generalización sobre los audios y logrando acercarse a una precisión de prueba rondando un 89%.

Al aislar el análisis sobre este mejor modelo (Configuración 2), se evaluaron sus gráficas de rendimiento.

En la gráfica de **Loss**, la curva de entrenamiento y la de validación descienden de manera más rápida y progresiva en comparación a configuraciones truncadas, acercándose asintóticamente a un valor inferior a 0.4. El uso de StepLR garantiza descensos estables a través del tiempo de cómputo,




Fig. 4. Pérdida de entrenamiento y validación para el mejor Modelo A (Configuración 2).

indicando menos señales de sobreajuste drástico durante casi todas las épocas.




Fig. 5. Precisión de entrenamiento y validación para el mejor Modelo A (Configuración 2).

Al examinar la gráfica de **Accuracy**, el modelo exhibe un aprendizaje firme. Muestra crecimientos significativos durante las primeras 15 épocas estabilizándose gradualmente hacia el ~88-89%. La reducción de escalón en la época 10 consolida esta precisión impidiendo inestabilidades en la fase final de ajuste.

En la gráfica de **F1-Score macro**, el progreso es consistente con la exactitud general. Alcanzar un F1 macro superior a 0.88 significa que el modelo adquirió un nivel equilibrado de sensibilidad y precisión en una amplia mayoría de las 10 clases de comandos, minimizando sesgos de preferencia causados por alguna clase individual.




Fig. 6. Evolución del F1-Score macro en validación para el mejor Modelo A (Configuración 2).




Fig. 7. Matriz de confusión del mejor Modelo A (Configuración 2) sobre los datos de prueba.

Como resultado en la matriz de confusión, el número de falsos positivos en relaciones conflictivas como las palabras muy cortas se reduce enormemente de forma visual. Sin embargo, a pesar de los buenos resultados que brinda este ajuste de hiperparámetros, la robustez nativa de la topología puramente convolucional (1×1) y activaciones tipo Tanh continúan siendo bastante primitivas debido al uso de los datos sin aumento espectral.

El rediseño del clasificador de este Modelo A es ligero y altamente favorecedor para un posible despliegue embebido, pero el uso de la aumentación de datos (como *Time Shift*, y *SpecAugment*) descrita en secciones previas será la pieza vital faltante para resolver la brecha sobre las discrepancias acústicas y elevar el Accuracy del entorno final.

C. Modelo A: Datos aumentados

Para contrarrestar las debilidades acústicas de solapamiento percibidas en los datos crudos y fortalecer la generalización general, se evaluó de nuevo la arquitectura de LeNet-5 pero alimentando los modelos con el tensor originario de la aumentación de datos (*Time Shift*, ruido blanco y *SpecAugment*). Con el fin de comparar justamente, se mantuvieron las mismas tres configuraciones hiperparamétricas previas.

TABLE V
RESULTADOS POR CONFIGURACIÓN - MODELO A (DATOS AUMENTADOS)

Configuración	Accuracy	F1-Score (Macro)	Loss
Configuración 1	0.8271	0.8262	0.5050
Configuración 2	0.8322	0.8316	0.4863
Configuración 3	0.8016	0.8004	0.5796

Pese al alto rendimiento visual en datos crudos, la validación del modelo se enriqueció visiblemente aquí por la **Configuración 2** obteniendo el mejor ajuste. Los datos aumentados son matemáticamente más densos, y el StepLR con lotes de 64 forzó a la red neuronal a no depender de características auditivas frágiles. Al estabilizar su exactitud sobre el $\sim 83.22\%$ y un envidiable *loss* de 0.48, el modelo resultante es considerablemente más tolerante a entornos no controlados (nuestro objetivo con el hardware embebido).

Al verificar visualmente el mejor modelo (Configuración 2) con datos aumentados:




Fig. 8. Pérdida de entrenamiento y validación para el mejor Modelo A aumentado.




Fig. 9. Precisión de entrenamiento y validación para el mejor Modelo A aumentado.

Las métricas escalan de una forma mucho menos abrumadora o inestable que con datos crudos. Las distorsiones de *White Noise* forzaron fluctuaciones moderadas que resultaron enriquecedoras como regularizador en épocas tempranas para prevenir por completo problemas de estancamiento.

La matriz de decaimientos demuestra que órdenes acústica o morfológicamente similares ahora tienen un recuadro de diagonales reforzado, confirmando que la aumentación de datos logró asilar firmas audibles crucialmente separables. A pesar de esto, se abre la brecha a experimentar un mejor comportamiento con modelos adaptados como MobileNetV2.




Fig. 10. Evolución del F1-Score macro para el mejor Modelo A aumentado.




Fig. 11. Matriz de confusión del Modelo A aumentado sobre el conjunto de prueba.

D. Modelo B: Datos crudos

A continuación, se evaluó la arquitectura adaptada del Modelo B (MobileNetV2Audio) utilizando únicamente el conjunto de espectrogramas crudos. A diferencia de LeNet-5, la inclusión de bloques *Inverted Residuals* suponía una clara ventaja en el reconocimiento visual y espacial del espectro sonoro. Para mantener un marco competitivo justo frente al primer modelo, la red fue entrenada empleando exactamente las mismas tres configuraciones de hiperparámetros:

- **Configuración 1:** Tasa de aprendizaje (LR) de 1×10^{-3} , tamaño de lote (BS) de 128, y ReduceLROnPlateau (factor=0.5, patience=3).
- **Configuración 2:** Tasa de aprendizaje de 5×10^{-4} , tamaño de lote de 64, y StepLR (step_size=10, gamma=0.5).
- **Configuración 3:** Tasa de aprendizaje de 2×10^{-3} , tamaño de lote de 256, y ReduceLROnPlateau más agresivo (factor=0.3, patience=5).

Los resultados consolidados para cada ensayo sobre el conjunto de prueba se presentan en la Tabla VI.

Inmediatamente se observa un salto masivo en precisión en comparación con la versión inicial del Modelo A. Para este modelo más sofisticado, la **Configuración 3** logró la victoria

TABLE VI
RESULTADOS POR CONFIGURACIÓN - MODELO B (DATOS CRUDOS)

Configuración	Accuracy	F1-Score (Macro)	Loss
Configuración 1	0.9592	0.9590	0.1826
Configuración 2	0.9552	0.9551	0.2073
Configuración 3	0.9633	0.9631	0.1430

absoluta superando el 96% de exactitud con un loss bajísimo (0.14). El tamaño de lote grande (256) complementado por una tasa de aprendizaje inicialmente robusta (2×10^{-3}) permitió rápidos avances a través del gradiente usando esta topología más profunda.

Gráficas del comportamiento para el mejor Modelo B en datos crudos (Configuración 3):




Fig. 12. Pérdida de entrenamiento y validación para el mejor Modelo B (datos crudos).




Fig. 13. Precisión de entrenamiento y validación para el mejor Modelo B (datos crudos).

Ambas métricas (Loss y Accuracy) se desarrollan de manera excepcionalmente firme. El modelo rápidamente alcanzó un Accuracy superior al 95% durante el entrenamiento temprano y preservó ese factor hasta el final.

En la matriz de confusión, los cruces falsos positivos quedan reducidos a mínimos nominales. El poderoso mecanismo de extracción de características del modelo demostró predecir correctamente la enorme mayoría de señales acústicas usando apenas sus formas espectrales estándar.

E. Modelo B: Datos aumentados

Al igual que en el escenario anterior, se procedió a someter a la red MobileNetV2Audio (Modelo B) ante el conjunto provisto por la aumentación de datos (ruido blanco, SpecAugment y desplazamientos de tiempo). Para mantener la coherencia




Fig. 14. Evolución del F1-Score macro para el mejor Modelo B (datos crudos).




Fig. 15. Matriz de confusión del Modelo B (datos crudos) sobre el conjunto de prueba.

comparativa, se utilizaron en esta fase las mismas tres configuraciones hiperparamétricas:

- **Configuración 1:** Tasa de aprendizaje (LR) de 1×10^{-3} , tamaño de lote (BS) de 128, y ReduceLRonPlateau (factor=0.5, patience=3).
- **Configuración 2:** Tasa de aprendizaje de 5×10^{-4} , tamaño de lote de 64, y StepLR (step_size=10, gamma=0.5).
- **Configuración 3:** Tasa de aprendizaje de 2×10^{-3} , tamaño de lote de 256, y ReduceLRonPlateau más agresivo (factor=0.3, patience=5).

Los resultados generales sobre los datos de prueba quedan plasmados en la Tabla VII.

TABLE VII
RESULTADOS POR CONFIGURACIÓN - MODELO B (DATOS AUMENTADOS)

Configuración	Accuracy	F1-Score (Macro)	Loss
Configuración 1	0.9497	0.9493	0.2317
Configuración 2	0.9435	0.9430	0.2534
Configuración 3	0.9507	0.9503	0.1523

En este escenario de espectrogramas alterados artificial-

mente, la **Configuración 3** reafirmó su superioridad al consolidar el Accuracy sobre un 95.07% y mantener un loss notablemente bajo (0.15). Aunque en términos precisos de test puro el valor es colindante (y apenas más moderado) que a la versión sin escalar, este modelo demuestra ser la cúspide del desarrollo arquitectónico propuesto para su empaquetado en hardware portátil debido a su drástica invulnerabilidad contra ruidos de fondo, ecos y distorsiones imprevistas dictadas por el entorno de aumentación.




Fig. 16. Pérdida de entrenamiento y validación para el mejor Modelo B aumentado.




Fig. 17. Precisión de entrenamiento y validación para el mejor Modelo B aumentado.




Fig. 18. Evolución del F1-Score macro para el mejor Modelo B aumentado.

Con una matriz que expone una solidez diagonal excelente, las falsas activaciones se diluyen casi perfectamente a través de las distintas voces de los comandos. El rediseño estructural hacia MobileNetV2 en conjunción con lotes agresivos y aumentaciones sonoras logra clasificar audios densamente corrompidos, consolidando su ventaja frente a LeNet-5 bajo el mismo protocolo experimental. El despliegue en dispositivo y la verificación de paridad se documentan en la Sección V.




Fig. 19. Matriz de confusión del Modelo B aumentado sobre el conjunto de prueba.

V. EXPORTACIÓN ONNX, PARIDAD Y APLICACIÓN MÓVIL

A. Congelación del modelo y exportación

Antes de exportar, el modelo se coloca en modo evaluación (`model.eval()`) para desactivar el comportamiento estocástico de capas como *dropout* y *batch normalization* en entrenamiento, y se congelan los pesos resultantes del mejor punto según validación. La exportación a ONNX se realiza con `torch.onnx.export` sobre un tensor de entrada ficticio de tipo `float32` y forma `(1,1,128,128)` en convención NCHW, alineada con las entradas descritas en las Tablas I y II. El archivo `.onnx` queda versionado junto con los hiperparámetros del mel y del entrenamiento para trazabilidad.

B. Comprobación de paridad frente a PyTorch

La paridad numérica se verifica alimentando al modelo PyTorch y al sesión ONNX Runtime con el *mismo* tensor de entrada (idealmente obtenido del mismo WAV tras el preprocesamiento bit-exacto). Se comparan los logits: se reporta el máximo error absoluto por componente y se comprueba que el `argmax` coincida en un conjunto de clips de prueba. La Fig. 20 ilustra el tipo de evidencia esperada (curva o tabla de errores); si el error supera un umbral pequeño fijado por el equipo, se revisa la pila de operadores soportados por ONNX Runtime o diferencias de redondeo en la STFT.

C. ONNX Runtime Mobile y contrato de preprocesamiento

En Android se añade la dependencia de ONNX Runtime Mobile al módulo de la aplicación, se empaqueta el `.onnx` bajo `assets/` y se crea una sesión de inferencia en CPU (o acelerador si se configura). El preprocesamiento en Kotlin o C++ debe reproducir exactamente el pipeline descrito en la Sección de dataset: frecuencia de muestreo 16 kHz, mono, ventana de 1 s, parámetros STFT/mel del cuaderno de entrenamiento y reescalado a 128×128 . Un checklist de contrato




Fig. 20. Evidencia de paridad PyTorch vs ONNX (figura a incorporar): error por componente o máximo $|\Delta|$ en logits.

orientado a despliegue (PCM16, ventana Hann, *hop*, banco mel HTK, normalización por muestra, etc.) se documenta en el código auxiliar del repositorio para evitar desviaciones silenciosas entre entrenamiento e inferencia.

D. Coherencia salida–acciones en la interfaz

La salida del clasificador es un vector de diez logits; el índice del máximo se mapea a la etiqueta lexica y de ahí a acciones de navegación o de control del hogar simulado (p. ej. conmutar dispositivos o rutinas). La aplicación de referencia está implementada en Jetpack Compose [8]; en la versión actual del repositorio la secuencia de comandos se demuestra mediante una rutina de prueba programada mientras se completa la integración con captura de audio (MediaRecorder [7]) y la sesión ONNX en el hilo de interfaz. La Fig. 21 reserva el espacio para una captura de pantalla una vez enlazada la inferencia en tiempo real.

VI. CONCLUSIONES

Se abordó el reconocimiento de diez comandos de voz sobre *Speech Commands* v0.02 con partición oficial train/val/test y representación mel reescalada a 128×128 . Doce entrenamientos (dos arquitecturas, datos crudos o aumentados, tres configuraciones de optimizador y lote) mostraron que MobileNetV2 supera de forma sostenida a LeNet-5: la mejor exactitud en prueba (0.9633) y F1 macro (0.9631) se obtuvieron con el Modelo B en datos crudos y Configuración 3 (Tabla III). La aumentación mejoró la robustez perceptual del Modelo A pero no igualó al Modelo B; en MobileNetV2 la aumentación redujo levemente la métrica frente a crudos,



Fig. 21. Aplicación Android: inferencia o demo de comandos (captura a incorporar).

fenómeno compatible con regularización más agresiva o con un techo ya alto del modelo base.

Desde el criterio móvil, MobileNetV2 ofrece un mejor equilibrio esperado entre precisión y coste computacional que LeNet-5 con mayor profundidad de extracción; el modelo seleccionado para despliegue debe ser el que maximice la métrica acordada en validación/prueba sujeto a restricciones de latencia, tamaño del archivo ONNX y memoria RAM en el terminal. La trazabilidad en Weights & Biases aporta evidencia auditable de cada corrida.

Como trabajo futuro queda cerrar el ciclo con exportación ONNX versionada, pruebas de paridad sistemáticas en dispositivo y sustituir la demo programada por inferencia continua sobre el micrófono con el mismo contrato de preprocesamiento descrito en este informe.

VII. REFERENCIAS

REFERENCES

- [1] D. S. Park, W. Chan, Y. Zhang, C.-C. Chiu, B. Zoph, E. D. Cubuk, and Q. V. Le, "SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition," in *Proc. INTERSPEECH*, 2019, pp. 2613–2617.
- [2] ONNX Runtime contributors, "ONNX Runtime," 2026. [Online]. Available: <https://onnxruntime.ai/>. [Accessed: May 4, 2026].
- [3] L. Biewald, "Experiment Tracking with Weights and Biases," Weights & Biases, San Francisco, CA, USA, 2020. [Online]. Available: <https://wandb.com/>. [Accessed: May 4, 2026].
- [4] TensorFlow, "TensorFlow Lite," 2026. [Online]. Available: <https://www.tensorflow.org/lite/guide>. [Accessed: May 2, 2026].
- [5] TensorFlow Datasets, "speech_commands," 2026. [Online]. Available: https://www.tensorflow.org/datasets/catalog/speech_commands. [Accessed: May 2, 2026].
- [6] PyTorch, "torchaudio," 2026. [Online]. Available: <https://docs.pytorch.org/audio/stable/index.html>. [Accessed: May 2, 2026].
- [7] Android Developers, "MediaRecorder," 2026. [Online]. Available: <https://developer.android.com/reference/android/media/MediaRecorder>. [Accessed: May 2, 2026].
- [8] Android Developers, "Get started with Jetpack Compose," 2026. [Online]. Available: <https://developer.android.com/develop/ui/compose/documentation>. [Accessed: May 2, 2026].